

Tarea Evaluativa de Optimización

Abel de la Noval Pérez

Grupo: C-311

Enlace del repositorio: <https://github.com/ABELNoval/Optimization-Evaluation-Homework->

1. Introducción y Definición del Problema

El presente trabajo aborda el análisis y optimización de la función no convexa definida por:

$$f(x, y) = 1 + \sin^2(x + 3) + \sin^2(y) - e^{-((x+3)^2+y^2)} \quad (1)$$

El objetivo principal consiste en identificar las propiedades fundamentales de esta función, implementar algoritmos de optimización adecuados para su minimización, y comparar el desempeño de dichos algoritmos bajo diferentes condiciones iniciales y parámetros de configuración.

2. Análisis Teórico del Modelo

2.1. Dominio y Propiedades Básicas

La función objetivo $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ tiene como dominio todo el plano $\mathbb{R}^2$, ya que todas las operaciones matemáticas involucradas (funciones trigonométricas y exponencial) están definidas para cualquier valor real de x e y .

La función es continua en todo su dominio por ser composición de funciones continuas elementales. Respecto a la acotación, se verifica que:

$$f(x, y) \geq 0 \quad \text{para todo } (x, y) \in \mathbb{R}^2 \quad (2)$$

Esta afirmación se sustenta en las desigualdades $\sin^2(\cdot) \geq 0$ y $e^{-((x+3)^2+y^2)} \leq 1$, lo que implica que:

$$f(x, y) = 1 + \sin^2(x + 3) + \sin^2(y) - e^{-((x+3)^2+y^2)} \geq 1 + 0 + 0 - 1 = 0 \quad (3)$$

El punto $(-3, 0)$ satisface $f(-3, 0) = 0$, confirmando que este valor mínimo global es alcanzable.

2.2. Análisis de Convexidad

Para determinar la convexidad de la función, se procede al cálculo y análisis de su matriz Hessiana. Inicialmente, se computa el gradiente:

$$\nabla f(x, y) = \begin{bmatrix} \sin(2(x + 3)) + 2(x + 3)e^{-((x+3)^2+y^2)} \\ \sin(2y) + 2ye^{-((x+3)^2+y^2)} \end{bmatrix} \quad (4)$$

Posteriormente, se calculan las segundas derivadas parciales para construir la matriz Hessiana:

$$H(x, y) = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} \quad (5)$$

donde:

$$\frac{\partial^2 f}{\partial x^2} = 2 \cos(2(x + 3)) + 2e^{-((x+3)^2+y^2)} [1 - 2(x + 3)^2] \quad (6)$$

$$\frac{\partial^2 f}{\partial y^2} = 2 \cos(2y) + 2e^{-((x+3)^2+y^2)} [1 - 2y^2] \quad (7)$$

$$\frac{\partial^2 f}{\partial x \partial y} = -4y(x + 3)e^{-((x+3)^2+y^2)} \quad (8)$$

El criterio para convexidad global exige que $H(x, y)$ sea semidefinida positiva para todo $(x, y) \in \mathbb{R}^2$. Sin embargo, al evaluar en puntos específicos se constatan violaciones a este requisito. Por ejemplo, en $(x, y) = (-3 + \pi/2, 0)$:

$$\frac{\partial^2 f}{\partial x^2} = 2 \cos(\pi) + 2e^{-(\pi/2)^2} [1 - 2(\pi/2)^2] = -2 + 2e^{-\pi^2/4} [1 - \pi^2/2] < 0 \quad (9)$$

La negatividad de esta segunda derivada parcial demuestra que la matriz Hessiana no es semidefinida positiva en todo el dominio, invalidando la convexidad global de la función.

2.3. Puntos Estacionarios

Los puntos estacionarios satisfacen $\nabla f(x, y) = 0$. Del sistema:

- De $\frac{\partial f}{\partial y} = \sin(2y) + 2ye^{-((x+3)^2+y^2)} = 0$ se obtiene que $y = 0$ es solución.
- Para x , debemos resolver la ecuación:

$$g(x) = \sin(2(x+3)) + 2(x+3)e^{-((x+3)^2+y^2)} = 0$$

Es inmediato que $x = -3$ es solución cuando $y = 0$.

Por lo tanto, $(-3, 0)$ es un punto estacionario.

Evaluando la Hessiana en el punto $(-3, 0)$:

$$\nabla^2 f(-3, 0) = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix} \quad (10)$$

Los valores propios de esta matriz son $\lambda_1 = 4$ y $\lambda_2 = 4$. Como ambos son positivos, el Hessiano es definido positivo en $(-3, 0)$, y por tanto, este punto es un mínimo local estricto.

Dado que $f(x, y) \geq 0$ y $f(-3, 0) = 0$, concluimos que $(-3, 0)$ es el mínimo global de la función.

3. Algoritmos de Optimización

3.1. Selección de Algoritmos

Para abordar el problema de optimización no convexo planteado, se seleccionaron dos algoritmos de entre los tres estudiados en clase: el método de Máximo Descenso (Gradiente Descendente) y el método Quasi-Newton BFGS.

En una función que presenta una gran cantidad de mínimos locales, resulta intrínsecamente difícil que los algoritmos basados en descenso —o, en general, cualquier método que dependa exclusivamente de información local del gradiente— logren alcanzar el mínimo global. Este tipo de métodos tiende a detenerse en el primer valle donde el gradiente se anula, lo cual hace muy improbable que puedan escapar y continuar explorando regiones del dominio que conduzcan a valores más bajos de la función. Por ello, los algoritmos de esta naturaleza no son los más adecuados para optimizar funciones altamente onduladas. Esto se explicará más a detalle en la sección del análisis de los resultados.

En consecuencia, la elección de estos métodos en el presente estudio no obedece a que sean particularmente apropiados para esta función, sino al objetivo de analizar su desempeño en un escenario adverso y de comparar las diferencias en sus dinámicas de convergencia bajo estas condiciones.

3.2. Algoritmo 1: Método de Máximo Descenso

El método de Máximo Descenso, también conocido como Gradiente Descendente, es un algoritmo de optimización de primer orden basado en la propiedad fundamental de que el gradiente de una función en un punto dado ($\nabla f(\mathbf{x}_k)$) indica la dirección de máximo ascenso local. Por lo tanto, moverse en la dirección opuesta ($-\nabla f(\mathbf{x}_k)$) garantiza el descenso más rápido posible.

La formulación iterativa del algoritmo es:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k \nabla f(\mathbf{x}_k) \quad (11)$$

donde:

- $\mathbf{x}_k \in \mathbb{R}^n$: punto actual en la iteración k
- $\nabla f(\mathbf{x}_k)$: vector gradiente de f evaluado en $\mathbf{x}_k$
- $\alpha_k > 0$: tamaño de paso o tasa de aprendizaje en la iteración k

Procedimiento Iterativo

1. **Inicialización:** Seleccionar punto inicial $\mathbf{x}_0$, tamaño de paso α , tolerancia ϵ , y número máximo de iteraciones K
2. **Para** $k = 0, 1, 2, \dots, K$:
 - a) Calcular el gradiente $\nabla f(\mathbf{x}_k)$
 - b) Verificar criterio de parada: si $\|\nabla f(\mathbf{x}_k)\| < \epsilon$, terminar
 - c) Actualizar posición: $\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \nabla f(\mathbf{x}_k)$
 - d) Incrementar contador: $k = k + 1$
3. **Salida:** Devolver $\mathbf{x}_k$ como aproximación del mínimo

3.3. Algoritmo 2: Método Quasi-Newton BFGS

El método Quasi-Newton BFGS (Broyden-Fletcher-Goldfarb-Shanno) es un algoritmo que aproxima el método de Newton sin requerir el cálculo explícito de la matriz Hessiana. En lugar de calcular la Hessiana exacta en cada iteración, construye y actualiza iterativamente una aproximación B_k de esta matriz.

La actualización del punto sigue la fórmula:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k B_k^{-1} \nabla f(\mathbf{x}_k) \quad (12)$$

La actualización BFGS para la aproximación del Hessiano inverso $H_k = B_k^{-1}$ es:

$$H_{k+1} = \left(I - \frac{s_k y_k^T}{y_k^T s_k} \right) H_k \left(I - \frac{y_k s_k^T}{y_k^T s_k} \right) + \frac{s_k s_k^T}{y_k^T s_k} \quad (13)$$

donde:

- $\mathbf{x}_k \in \mathbb{R}^n$: punto actual en la iteración k
- H_k : aproximación actual de la inversa del Hessiano
- $s_k = \mathbf{x}_{k+1} - \mathbf{x}_k$: diferencia entre iteraciones sucesivas
- $y_k = \nabla f(\mathbf{x}_{k+1}) - \nabla f(\mathbf{x}_k)$: diferencia entre gradientes sucesivos
- α_k : tamaño de paso obtenido por búsqueda lineal

Procedimiento Iterativo

1. **Inicialización:** Seleccionar $\mathbf{x}_0$, $H_0 = I$ (matriz identidad), tolerancia ϵ , y número máximo de iteraciones K
2. **Para** $k = 0, 1, 2, \dots, K$:
 - a) Calcular dirección de descenso: $\mathbf{p}_k = -H_k \nabla f(\mathbf{x}_k)$
 - b) Realizar búsqueda lineal para encontrar α_k que minimice $f(\mathbf{x}_k + \alpha_k \mathbf{p}_k)$
 - c) Actualizar posición: $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k$
 - d) Calcular $s_k = \mathbf{x}_{k+1} - \mathbf{x}_k$ y $y_k = \nabla f(\mathbf{x}_{k+1}) - \nabla f(\mathbf{x}_k)$
 - e) Actualizar H_{k+1} usando la fórmula BFGS
 - f) Verificar criterio de parada: si $\|\nabla f(\mathbf{x}_{k+1})\| < \epsilon$, terminar
 - g) Incrementar contador: $k = k + 1$
3. **Salida:** Devolver $\mathbf{x}_k$ como aproximación del mínimo

4. Análisis de los Resultados de los Algoritmos de Optimización

En total se realizaron 5292 experimentos. Para ello, primero se generaron 441 puntos iniciales distribuidos uniformemente en el intervalo $[-100, 100]$ para cada coordenada, utilizando incrementos de 10 unidades y considerando todas las combinaciones posibles. Sobre cada uno de estos puntos se ejecutaron dos algoritmos: Gradient Descent y BFGS. En el caso de Gradient Descent, se evaluaron tres valores distintos de *learning rate* (0.001, 0.01 y 0.1) y tres límites de iteraciones (100, 500 y 1000), lo que produce 9 configuraciones por punto inicial, acumulando un total de 3969 ejecuciones. Para BFGS, se consideraron tres límites de iteraciones (100, 500 y 1000) usando un *learning rate* fijo de 0.01, resultando en 3 configuraciones por punto inicial y alcanzando 1323 ejecuciones adicionales. La suma de ambas modalidades da lugar a los 5292 experimentos efectuados.

De forma teórica, el **mínimo global** se encuentra en el punto:

$$(x^*, y^*) = (-3, 0), \quad \text{con } f(x^*, y^*) = 0.$$

Sin embargo, al ejecutar los métodos de **Máximo Descenso** y **Quasi-Newton (BFGS)** sobre el dominio comprendido entre -100 y 100 para ambas variables, se observa que los algoritmos rara vez alcanzan dicho mínimo global. En su lugar, convergen en valores mayores, correspondientes a **mínimos locales**. Esto no es un fallo de los métodos, sino una consecuencia directa de la estructura de la función a optimizar.

La expresión $1 + \sin^2(x + 3) + \sin^2(y)$ introduce una superficie periódica caracterizada por un patrón repetitivo de valles y crestas distribuidos a lo largo de todo el plano. Sobre esta superficie se superpone el término gaussiano negativo $-\exp(-((x + 3)^2 + y^2))$, que genera un pozo profundo centrado en $(-3, 0)$ —el único mínimo global— pero cuya influencia decrece de manera exponencial a medida que uno se aleja de dicho centro. El resultado son unas infinitas depresiones poco profundas producidas por los términos $\sin^2$, y un único valle muy profundo y localizado debido al término exponencial.

En este tipo de paisajes, los algoritmos dependientes del gradiente presentan una limitación estructural: tienden a seguir la dirección de máxima pendiente descendente en su entorno inmediato, lo que los lleva a caer en el primer valle que encuentran. Una vez atrapados en un mínimo local, el gradiente se anula y no existe información suficiente para escapar hacia regiones más prometedoras del dominio. Por ello, aun cuando el mínimo global es claramente más profundo, los métodos de optimización clásicos sólo pueden alcanzarlo si el punto inicial

se encuentra razonablemente cerca de $(-3,0)$ o si su trayectoria evita accidentalmente los numerosos valles intermedios, algo altamente improbable en un rango tan amplio como el considerado.

Comparación de resultados




Figura 1: Experimento más cercano al mínimo global en el algoritmo GD.




Figura 2: Experimento más cercano al mínimo global en el algoritmo BFGS.

En primer lugar, se presentan las visualizaciones correspondientes a los casos en los que ambos algoritmos, Gradient Descent (GD) y el método quasi-Newton BFGS, alcanzan sus mejores desempeños. En estos escenarios, caracterizados por puntos iniciales relativamente

cercanos al mínimo global $(-3, 0)$, el comportamiento de ambos métodos es similar y no se observan diferencias significativas ni en la calidad de la solución alcanzada ni en la localización final dentro del paisaje de la función. Este resultado es coherente con la teoría: cuando el punto inicial se encuentra dentro de una región bien condicionada y de curvatura favorable, ambos algoritmos descienden de manera efectiva hacia la misma cuenca de atracción.




Figura 3: Experimento más lejano al mínimo global — algoritmo GD




Figura 4: Experimento más lejano al mínimo global — algoritmo BFGS

Cuando los puntos iniciales están lejos del mínimo global, el comportamiento de los algoritmos cambia bastante. Gradient Descent sigue siendo lento, pero su avance es estable y predecible, con pasos pequeños que evitan desviaciones fuertes. Esto hace que, aunque tarde más, normalmente no se aleje de la zona donde debería optimizar.

En cambio, BFGS puede volverse mucho más inestable lejos del mínimo. Como está estimando constantemente la curvatura, a veces genera pasos muy grandes que lo sacan de la

región de interés. Por eso, en algunos casos, incluso empezando más cerca del mínimo global, BFGS termina más lejos que Gradient Descent, simplemente porque sus saltos amplios lo desvían del camino óptimo.

initial_point	final_value	distance	iterations_param	learning_rate	steps
(0, 0)	0.999948	3.141430	1000	0.10	57
(0, 0)	0.999948	3.141430	500	0.10	57
(0, 0)	0.999948	3.141430	100	0.10	57
(0, 0)	0.999948	3.141424	1000	0.01	623
(0, 0)	0.999948	3.141424	500	0.01	500
(20, 90)	1.000000	93.722718	500	0.10	71
(20, 100)	1.000000	102.908141	500	0.10	69
(20, 100)	1.000000	102.908141	1000	0.10	69
(20, 100)	1.000000	102.908141	100	0.10	69
(60, 40)	1.000000	74.938674	500	0.10	67

Cuadro 1: Resultados de los 10 mejores experimentos del algoritmo GD.

initial_point	final_value	distance	iterations_param	learning_rate	steps
(0, 0)	0.999948	3.141405	1000	NaN	1000
(0, 0)	0.999949	3.140520	500	NaN	500
(-50, 0)	1.000000	47.123866	1000	NaN	1000
(60, 0)	1.000000	62.831880	1000	NaN	1000
(-90, 100)	1.000000	133.582367	1000	NaN	1000
(-90, -100)	1.000000	133.582367	1000	NaN	1000
(-50, -50)	1.000000	68.900472	1000	NaN	1000
(-50, 50)	1.000000	68.900472	1000	NaN	1000
(0, -50)	1.000000	50.363529	1000	NaN	1000
(0, 50)	1.000000	50.363529	1000	NaN	1000

Cuadro 2: Resultados de los 10 mejores experimentos del algoritmo BFGS.

algorithm	top_n_used	converged_count	avg_distnace	avg_time_proxy
<i>gradient_descent</i>	10	0	49.309296	0.708946
<i>quasi_newton_bfgs</i>	10	0	62.193041	0.062507

Cuadro 3: Comparativa entre los resultados de los 10 mejores experimetnos de ambos algoritmos

Finalmente, la tabla comparativa basada en los diez mejores experimentos de cada algoritmo confirma de manera cuantitativa las observaciones visuales anteriores. Ambos algoritmos muestran capacidades comparables cuando las condiciones iniciales son favorables,

pero BFGS exhibe una variabilidad mayor y una menor robustez conforme la distancia al mínimo inicial aumenta. Gradient Descent, aunque más lento, demuestra ser más estable y consistente frente a condiciones iniciales adversas.

5. Conclusiones

La estructura altamente ondulada de la función, con una gran cantidad de mínimos locales, condiciona fuertemente el desempeño de cualquier algoritmo basado en información local del gradiente. Como era de esperar, ni Máximo Descenso ni BFGS logran alcanzar el mínimo global $(-3, 0)$, dado que ambos métodos tienden a quedar atrapados en el primer valle donde el gradiente se anula.

A pesar de esta limitación estructural, es posible identificar diferencias claras entre ambos algoritmos. El método Quasi-Newton (BFGS) muestra un rendimiento superior cuando se inicia en regiones razonablemente cercanas al mínimo global o en zonas donde la curvatura de la función es suave y bien condicionada. Su aproximación de la matriz Hessiana le permite realizar pasos más informados y converger de manera rápida y estable en estos entornos locales.

Por otro lado, Gradient Descent exhibe un comportamiento más uniforme y robusto frente a puntos iniciales alejados, especialmente en partes del dominio donde la función presenta variaciones abruptas o cuencas estrechas. Aunque su convergencia suele ser más lenta y, en la práctica, no evita quedar atrapado en mínimos locales, su simplicidad lo hace menos sensible a irregularidades puntuales del paisaje.

En síntesis, BFGS resulta más eficiente cuando la región de partida se encuentra cerca del mínimo global o en zonas bien condicionadas, mientras que Gradient Descent se mantiene más estable ante variaciones amplias del punto inicial. Sin embargo, para funciones con topografías tan irregulares como la estudiada, ninguno de los dos métodos es apropiado para garantizar la localización del mínimo global, lo que refuerza la importancia de elegir algoritmos alternativos cuando se enfrentan funciones con múltiples atractores locales.